APPRENTISSAGE DE REPRÉSENTATION

Vincent Guigue,
inspiré des supports de Nicolas Baskiotis & Benjamin Piwowarski

MIA PARIS-SACLAY EKINOCS

INRAE AgroParisTech université PARIS-SACLAY

Introduction

Chaine de traitements

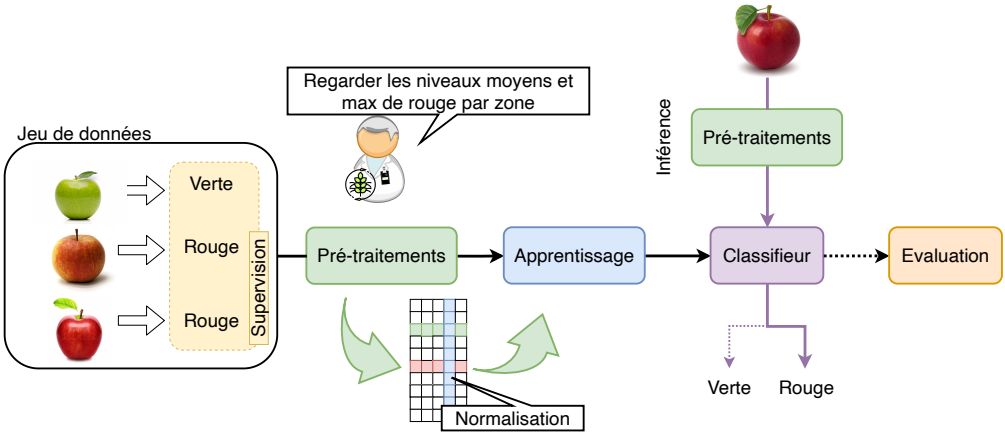

Facteur de performances: *features* > modèle

Promesse du deep-learning

- Apprendre des représentations continues de concepts **discrets** (+métrique continue)
  - Sémantique des **mots**, profils **utilisateurs**
- Apprendre des représentations compactes de concepts **continus**
  - Représentation des images, extraction de motifs dans les signaux

Int. Conf. on Learning Representations (ICLR)

Optimiser les caractéristiques extraites pour une applications cibles

~~Deep-learning~~ $\Rightarrow$ Representation Learning

Pourquoi est ce que ça marche si bien sur des données complexes+sémantiques mais moins bien sur des données tabulaires?

Grinsztajn et al., NeurIPS 22
Why do tree-based models still outperform deep learning on tabular data?

Une frontière floue entre représentation et décision

Exemple de la détection d'objets dans les images:

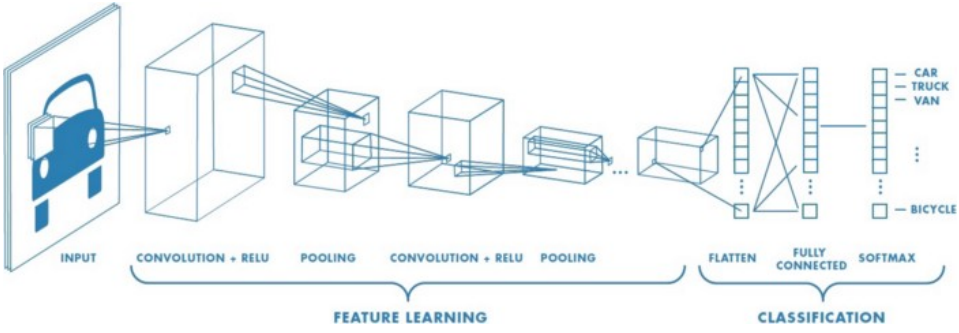

- Dernière couche de caracéristiques idéales =

  1 / objet présent + 0 /objet absent

- Souhaite-t-on vraiment une représentation qui décide?

  ECOC, notion de distance...

Représentation d'éléments discrets ou continus?

Machine Learning = difficile de représenter des éléments discrets:
variables catégorielles, mots, utilisateur

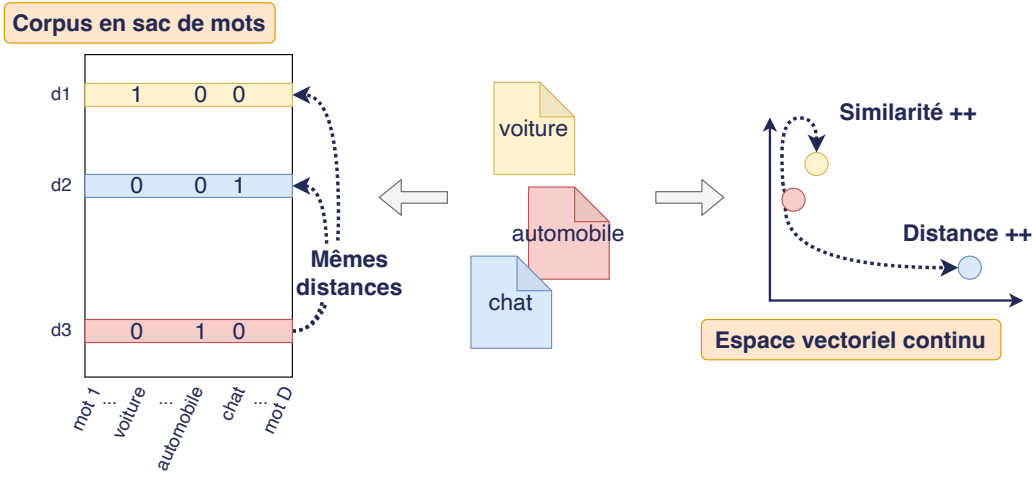

Objectif: introduire la notion de distance $\neq$ orthogonalité entre les catégories

Representation learning & transfer

1. Apprendre la représentation

   sur n'importe quel critère

2. Fine-tuner = apprendre un peu

   Sur la tâche finale / sur peu de données etc...

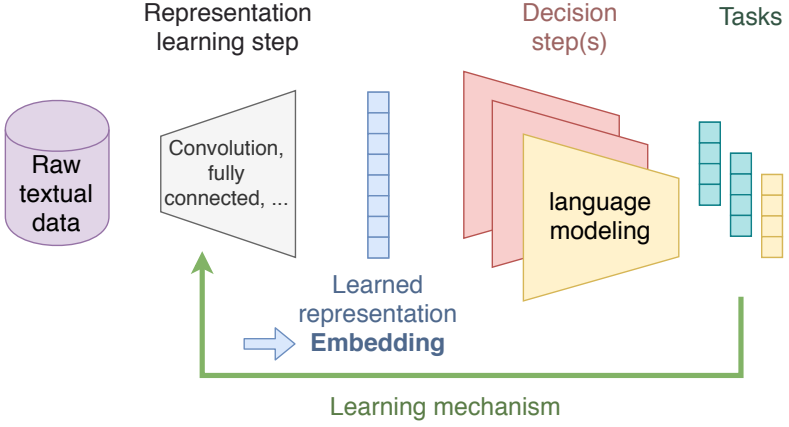

Architectures d'Apprentissage de représentation

Apprentissage de représentation

- Domaines : recommandation, représentation de graphes, classification multi-labels multi-classes, séparation sources audio, radar
- Appris en end-to-end, pré-appris et/ou fine-tuné
- Parfait pour la supervision est indirecte : similarité par triplet, contexte, ...

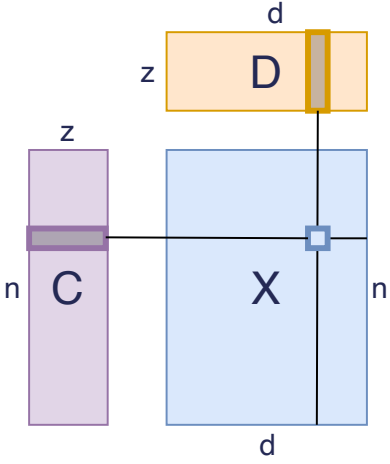

Apprentissage de représentation

- Domaines : recommandation, représentation de graphes, classification multi-labels multi-classes, séparation sources audio, radar
- Appris en end-to-end, pré-appris et/ou fine-tuné
- Parfait pour la supervision est indirecte : similarité par triplet, contexte, ...

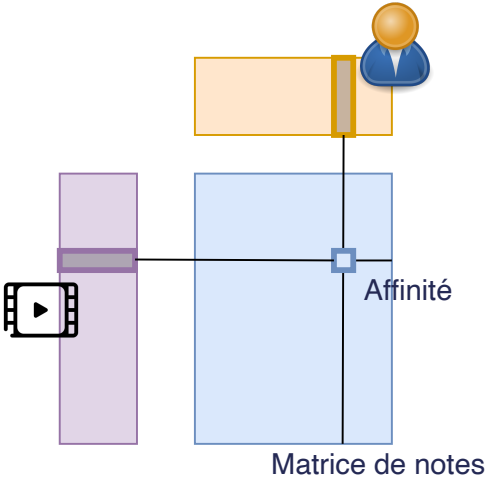

Apprentissage de représentation

- Domaines : recommandation, représentation de graphes, classification multi-labels multi-classes, séparation sources audio, radar
- Appris en end-to-end, pré-appris et/ou fine-tuné
- Parfait pour la supervision est indirecte : similarité par triplet, contexte, ...

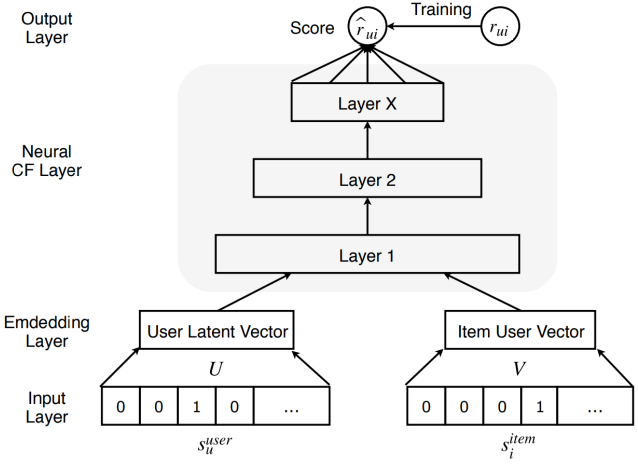

Apprentissage de représentation

- Domaines : recommandation, représentation de graphes, classification multi-labels multi-classes, séparation sources audio, radar
- Appris en end-to-end, pré-appris et/ou fine-tuné
- Parfait pour la supervision est indirecte : similarité par triplet, contexte, ...
- Possibilité d'utiliser des auto-encoders

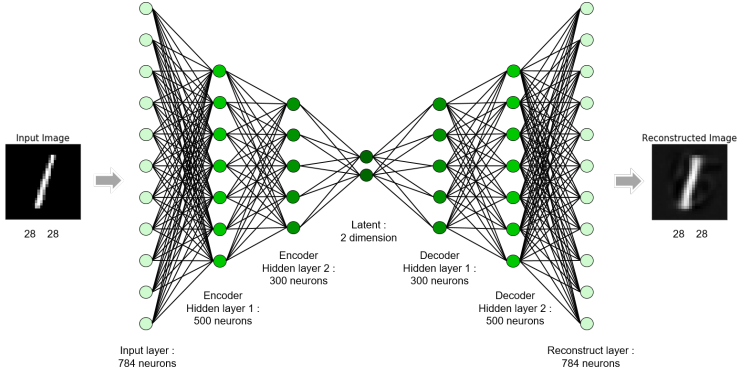

Structurer l'espace appris

- Variational AutoEncoder
- Reparameterization Trick

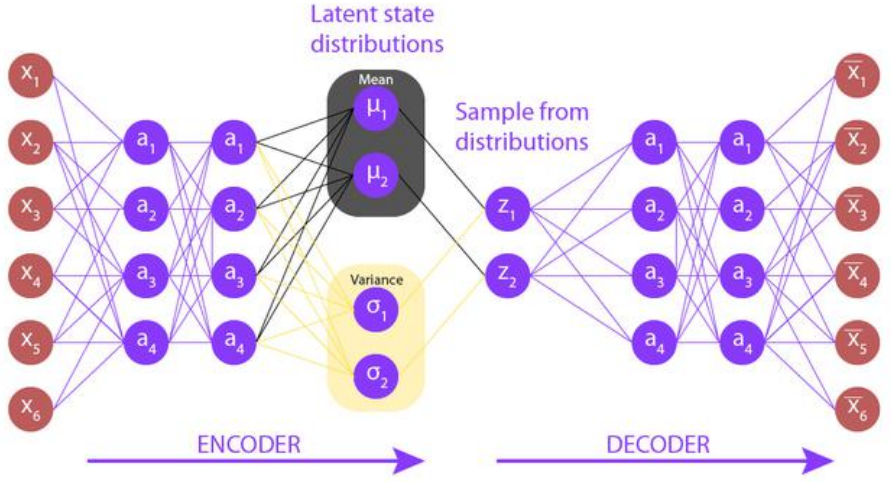

Représentation & explicabilité

Hypothèse: expliquer un processus = décomposer sur un dictionnaire *réduit* & *intelligible*

Input	→	Repr. latente	→	dictionnaire
Discret/Continu		Continu ⇒ distance		Discret

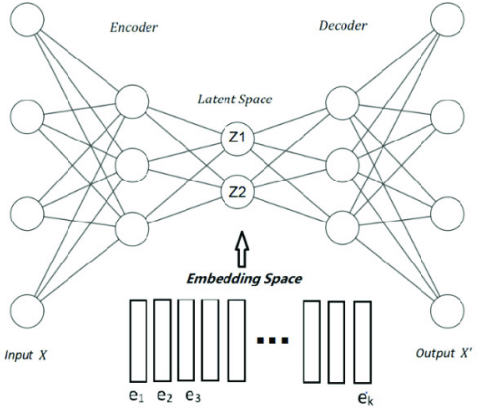

Deep LVQ

- LVQ = Learning vector quantization
- Idée $\sim$ plus proche voisin
- $+$ deep learning = apprendre la représentation des supports

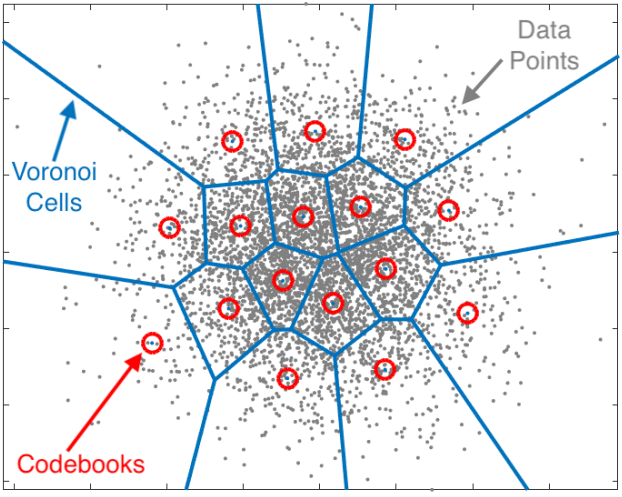

Applications (efficaces)

Deep learning et données textuelles

1. Des sacs de mots aux représentations vectorielles [2008, 2013, 2016]

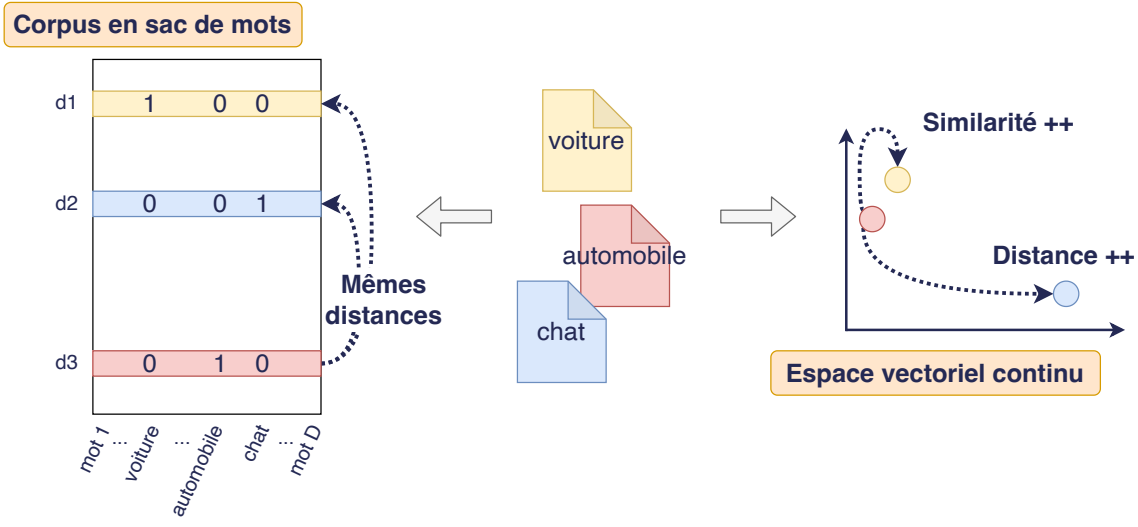

Word2Vec : extracting local semantics [Mikolov, 2013]

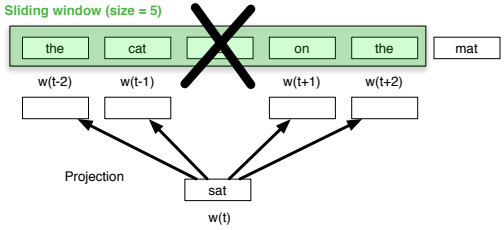

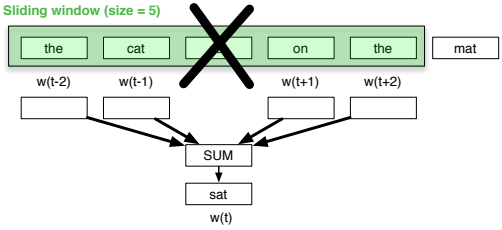

Skip-Gram (& *negative sampling* implementation) : easy learning

- Local analysis
- *predictive* criterion : estimating missing value
- Sliding window = local context C of word w

Mikolov, Sutskever, Chen, Corrado, Dean, NIPS 2013 (arXiv 2012)
Distributed representations of words and phrases and their compositionality

Word2Vec : extracting local semantics [Mikolov, 2013]

he curtains open and the moon shining in on the barely
ars and the cold , close moon " . And neither of the w
rough the night with the moon shining so brightly , it
made in the light of the moon . It all boils down , wr
surely under a crescent moon , thrilled by ice-white
sun , the seasons of the moon ? Home , alone , Jay pla
m is dazzling snow , the moon has risen full and cold
un and the temple of the moon , driving out of the hug
in the dark and now the moon rises , full and amber a
bird on the shape of the moon over the trees in front
But I could n't see the moon or the stars , only the
rning , with a sliver of moon hanging among the stars
they love the sun , the moon and the stars . None of
the light of an enormous moon . The plash of flowing w
man 's first step on the moon ; various exhibits , aer
the inevitable piece of moon rock . Housing The Airsh
oud obscured part of the moon . The Allied guns behind

(1) Initialisation aléatoire des positions des mots

Skip-Gram (& *negative sampling* implementation) : easy learning

- Local analysis
- *predictive* criterion : estimating missing value
- Sliding window = local context C of word w

Mikolov, Sutskever, Chen, Corrado, Dean, NIPS 2013 (arXiv 2012)
Distributed representations of words and phrases and their compositionality

Word2Vec : extracting local semantics [Mikolov, 2013]

he curtains open and the moon shining in on the barely
ars and the cold , close moon " . And neither of the w
rough the night with the moon shining so brightly , it
made in the light of the moon . It all boils down , wr
surely under a crescent moon , thrilled by ice-white
sun , the seasons of the moon ? Home , alone , Jay pla
m is dazzling snow , the moon has risen full and cold
un and the temple of the moon , driving out of the hug
in the dark and now the moon rises , full and amber a
bird on the shape of the moon over the trees in front
But I could n't see the moon or the stars , only the
rning , with a sliver of moon hanging among the stars
they love the sun , the moon and the stars . None of
the light of an enormous moon . The plash of flowing w
man 's first step on the moon ; various exhibits , aer
the inevitable piece of moon rock . Housing The Airsh
oud obscured part of the moon . The Allied guns behind

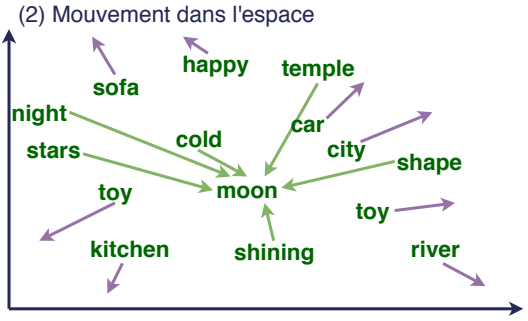

Skip-Gram (& *negative sampling* implementation) : easy learning

- Local analysis
- *predictive* criterion : estimating missing value
- Sliding window = local context C of word w

Mikolov, Sutskever, Chen, Corrado, Dean, NIPS 2013 (arXiv 2012)
Distributed representations of words and phrases and their compositionality

W2V : detailed explaination

- Given word w and local contexts C:

$$\text{Idée SG: } \arg\max_{\theta} \prod_{C} \prod_{w \in C} p(C|w;\theta)$$

- $p(D = 1|w_i, w_j; \theta) \Rightarrow$ proba. that w_i and w_j occur in the same context

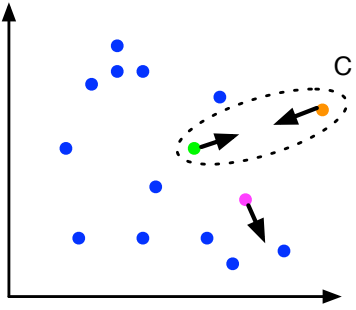

$$\arg\max_{\theta} \prod_{i,j \in C} p(D = 1|w_i, w_j; \theta) + \underbrace{\prod_{i,j \in \bar{C}} p(D = 0|w_i, w_j; \theta)}_{\text{Negative Sampling}}$$

Goldberg, Levy, arXiv 2014
word2vec Explained: Deriving Mikolov et al.'s Negative-Sampling Word-Embedding Method

Hammer, NN 2002
Generalized Relevance Learning Vector Quantization

W2V : Skip-gram & negative sampling

$$\arg\max_{\theta} \prod_{i,j \in C} p(D=1|w_i, w_j; \theta) + \underbrace{\prod_{i,j \in \bar{C}} p(D=0|w_i, w_j; \theta)}_{\text{Negative Sampling}}$$

- Using logistic function : $p(D=1|w_i, w_j) = \frac{1}{1+\exp(-\boldsymbol{z}_i \boldsymbol{z}_j)}$
- Global log-likelihood : $\arg\max_{Z} \left(\sum_{i,j \in C} \log \sigma(\boldsymbol{z}_i \cdot \boldsymbol{z}_j) + \sum_{i,j \in \bar{C}} \log \sigma(-\boldsymbol{z}_i \cdot \boldsymbol{z}_j) \right)$

σ : fct sigmoide, C : Set of Cooccurences, $\bar{C}$: Set of Non-Cooc

- Stochastic Gradient Descent + triplet loss
- Frequent word subsampling trick : picking words with $p(w_i) = 1 - \sqrt{\frac{t}{freq(w_i)}}, \qquad t = 10^{-5}$

Deep learning et données textuelles

Des mots aux tokens

Décomposition en groupes de lettres fréquents

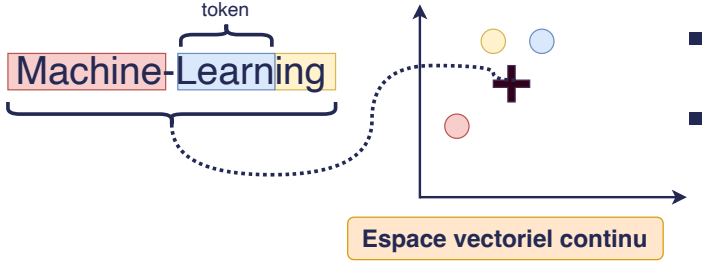

- Représentation des mots inconnus
- Résistance aux fautes d'orthographe

Deep learning et données textuelles

2. Agrégation des représentations de mots [2014, 2017]

Deep learning et données textuelles

2. Agrégation des représentations de mots [2014, 2017]

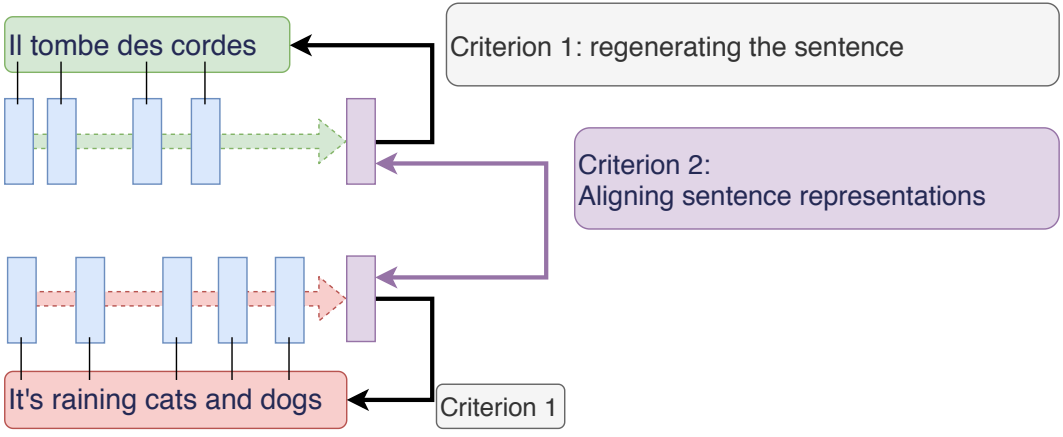

Deep learning et données textuelles

2. Agrégation des représentations de mots [2014, 2017]

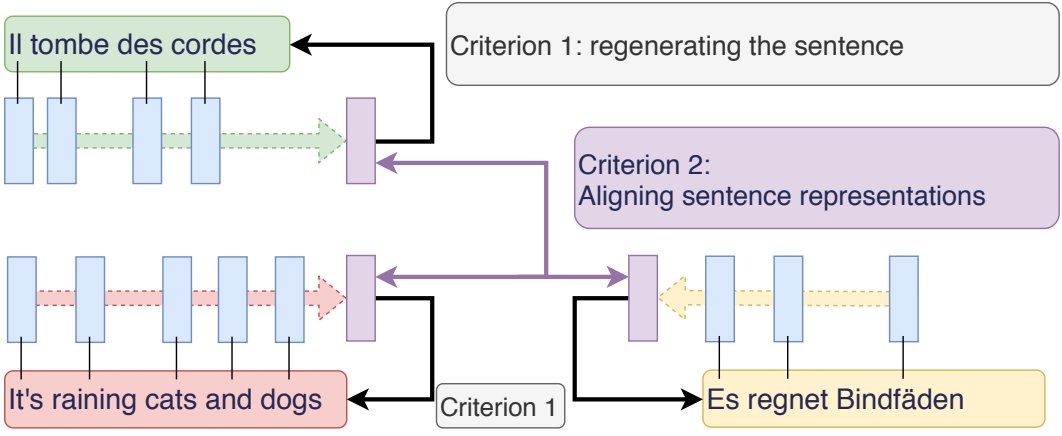

Recommandation

- 2001-2010 : Apprendre des profils à partir de trace = factorisation matricielle
- Déjà un modèle de deep-learning?

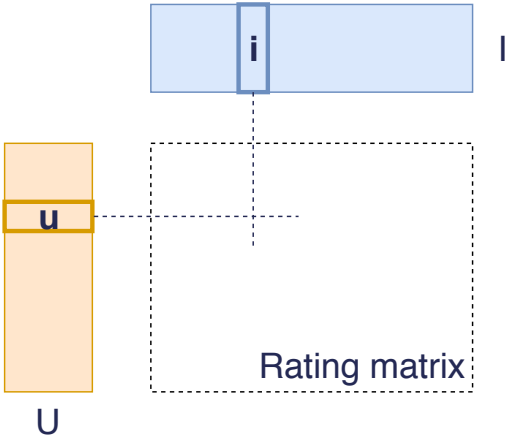

Profils se ressemblent ⇒ prédisent les mêmes notes

ATTENTION: réfléchir à la manière dont sont stockées ces données parcimonieuses/*sparses*

ATTENTION (2): Combien de paramètres, combien de notes à prédire?

Recommandation

- 2001-2010 : Apprendre des profils à partir de trace = factorisation matricielle
- Déjà un modèle de deep-learning?

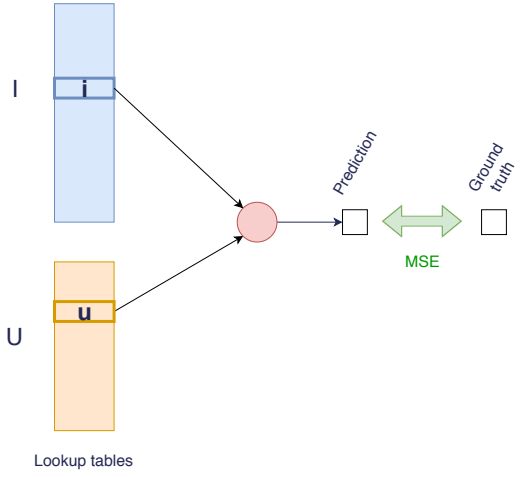

Profils se ressemblent ⇒ prédisent les mêmes notes

ATTENTION: réfléchir à la manière dont sont stockées ces données parcimonieuses/*sparses*

ATTENTION (2): Combien de paramètres, combien de notes à prédire?

Recommandation

- 2001-2010 : Apprendre des profils à partir de trace = factorisation matricielle
- Déjà un modèle de deep-learning?

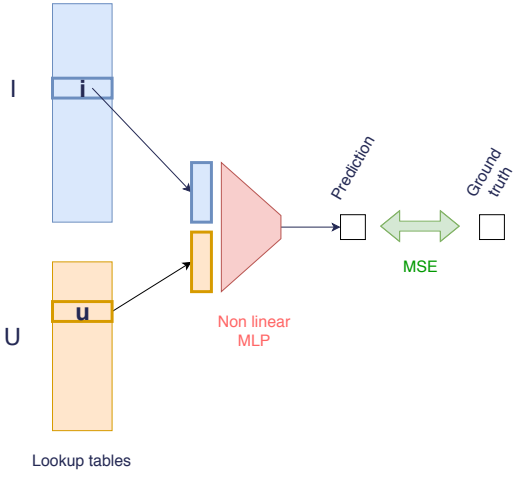

Profils se ressemblent ⇒ prédisent les mêmes notes

ATTENTION: réfléchir à la manière dont sont stockées ces données parcimonieuses/*sparses*

ATTENTION (2): Combien de paramètres, combien de notes à prédire?

Cas des sytèmes de recommandation

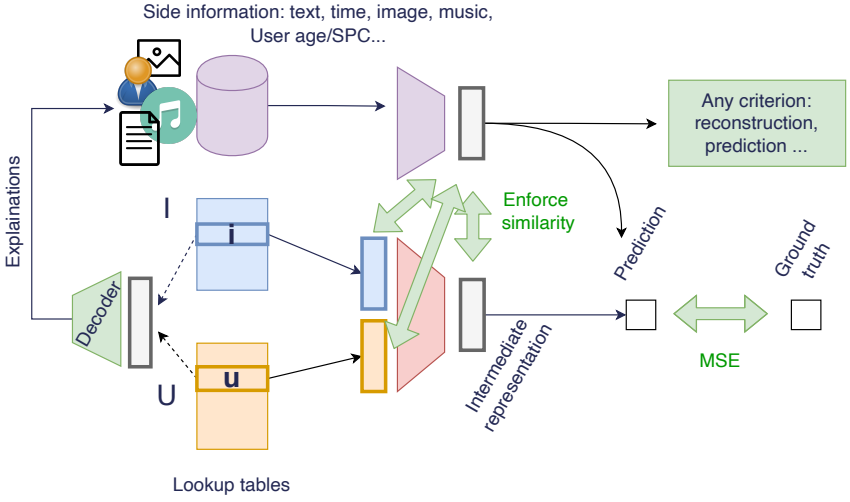

- Richesse des profils = performances [encodage ++]
- Expliquer le contenu des profils = xAI [décodage ++]

Vers des embbedings multi-modaux: CLIP

Contrastive Language-Image Pre-training = CLIP

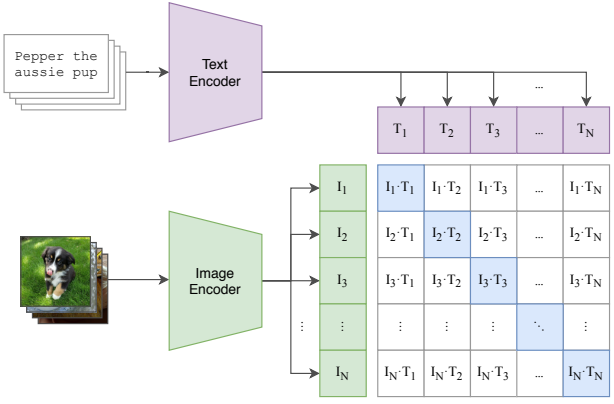

- Image encoder = ResNet-50, 101, ViT, ...
- Text encoder = DistillBERT, ...
- 400M paires images+textes
- Contrastive learning

Vers des embbedings multi-modaux: CLIP

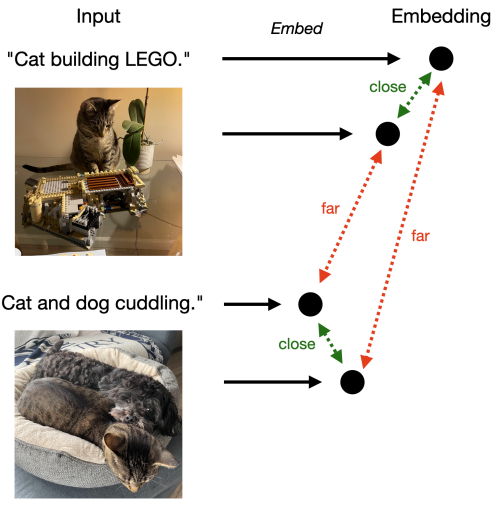

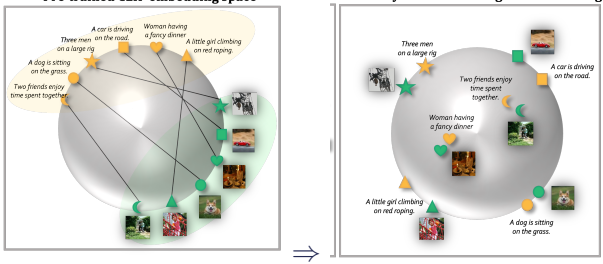

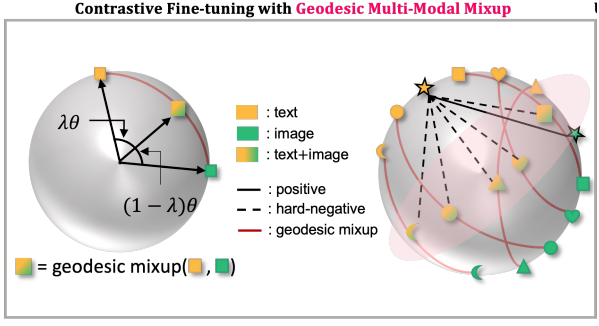

Vers des embbedings multi-modaux: CLIP

Exemple d'utilisation : cosine score entre $Enc(Im) \cdot Enc(Txt)$

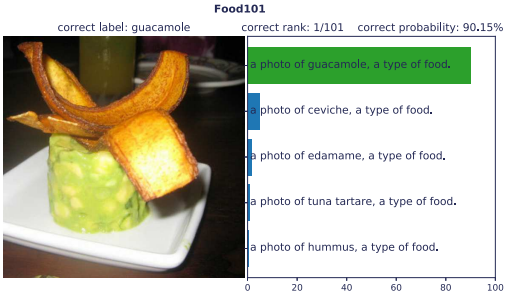

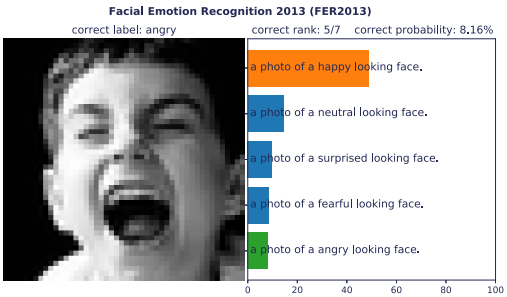

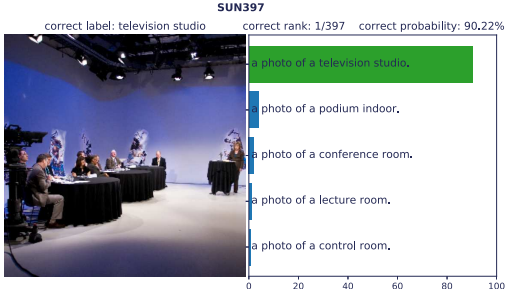

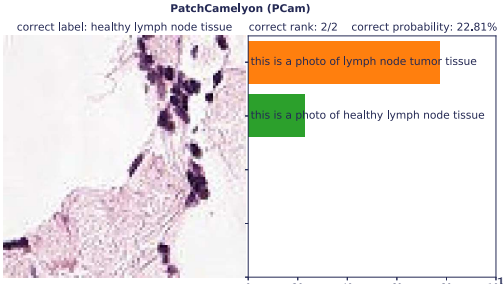

Vers des embbedings multi-modaux: CLIP

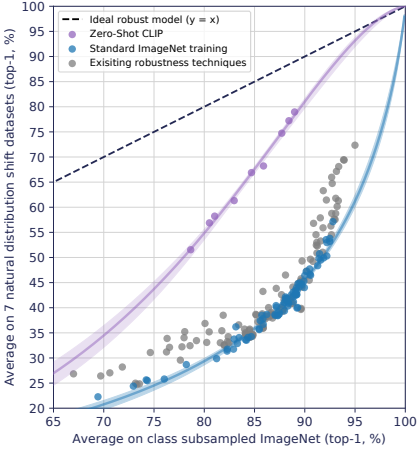

Sortir de la boite noire

- Expliquer une décision (Instance Feature Attribution)
  - LIME, SHAP,...

- Espace latent = boite noire...

	Que faire?
1 **Structurer** l'espace: VAE, GAN	$\Rightarrow$ + Prototypes
2 **Explorer** l'espace: conterfactual	$\Rightarrow$ Montrer & générer des exemples
3 **Décoder** l'espace: approche générative	$\Rightarrow$ Parler à l'utilisateur

Sortir de la boite noire

- Expliquer une décision (Instance Feature Attribution)
  - LIME, SHAP,...
- Espace latent = boite noire...

Que faire?

1. **Structurer** l'espace: VAE, GAN ⇒ + Prototypes
2. **Explorer** l'espace: conterfactual ⇒ Montrer & générer des exemples
3. **Décoder** l'espace: approche générative ⇒ Parler à l'utilisateur

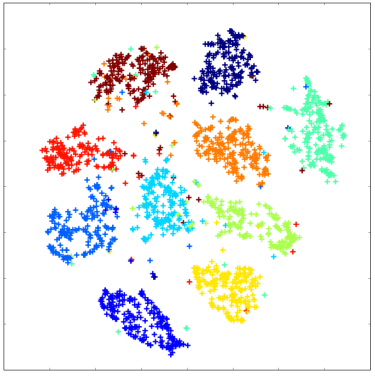

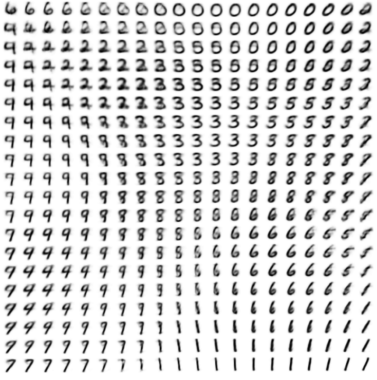

Sortir de la boite noire

- Expliquer une décision (Instance Feature Attribution)
  - LIME, SHAP,...
- Espace latent = boite noire...

	Que faire?
1 **Structurer** l'espace: VAE, GAN	$\Rightarrow$ + Prototypes
2 **Explorer** l'espace: conterfactual	$\Rightarrow$ Montrer & générer des exemples
3 **Décoder** l'espace: approche générative	$\Rightarrow$ Parler à l'utilisateur

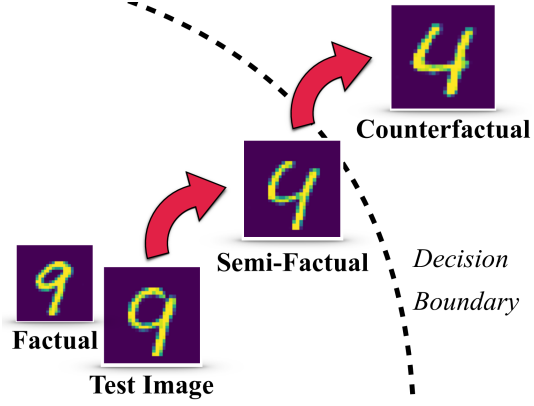

Visualisation de données

- Auto-encodeur $\Rightarrow$ 2D = visualisation de MNIST
- Passage au VAE (toujours non supervisé)

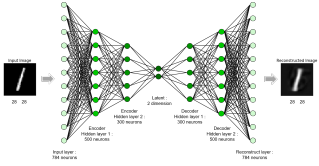

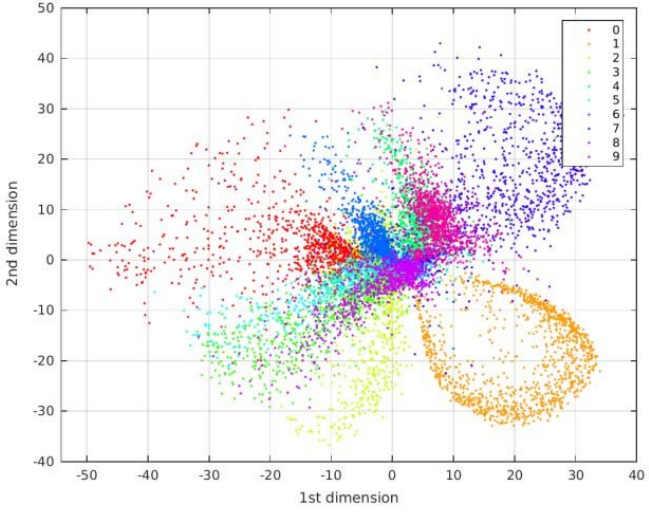

Visualisation de données

- Auto-encodeur $\Rightarrow$ 2D = visualisation de MNIST
- Passage au VAE (toujours non supervisé)

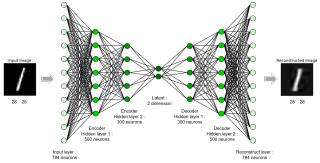

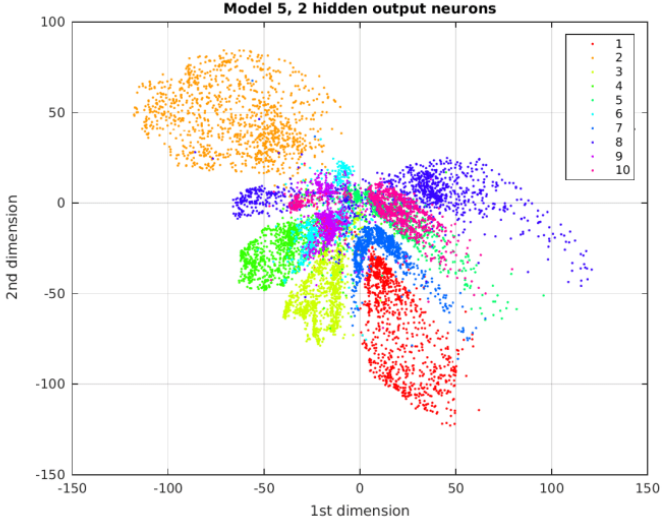

MusiCNN

- Convolution sur la transformée temps-fréquences
- Apprentissage d'embedding de musique
  - Pour la classification / recommandation
  - Pour la génération

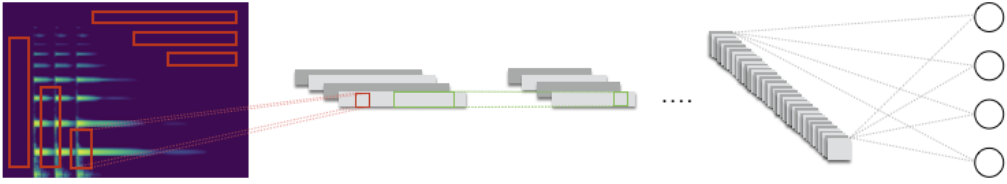

Décomposition de signaux

VQ-VAE-GAN : Reconstruire une entrée...

- A partir d'un ensemble de motifs finis
- En la rendant indiscernable de son originale !

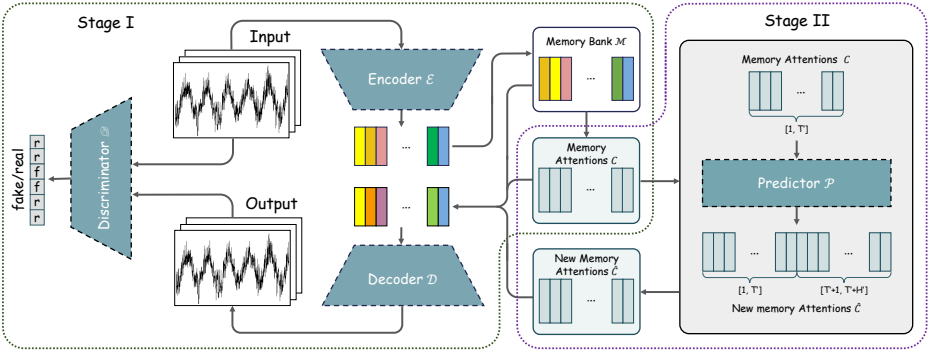

Figure 1: Overview of MATS. The left half part shows the first stage components and the right half part show the second stage components.

Outils connexes pour le TP

Représentations en pytorch

Représentation = vecteur + gradient activé

Hypothèse: dans un problème de recommandation, je modélise les notes par 3 scalaires

- composante globale, composante utilisateur, composante item

$$r_{ui} = \mu + b_u + b_i$$

- Initialiser les *représentations* à apprendre

```
1  mu = torch.tensor([3.5], requires_grad=True) # activate gradient to be able to le
2  bu = [torch.tensor([0.1], requires_grad=True) for _ in range(num_users)]
3  bi = [torch.tensor([0.1], requires_grad=True) for _ in range(num_items)]
```

- Utiliser ces grandeurs pour la prédiction
- Ajouter une fonction de coût (e.g. MSE)
- Retro-propager l'erreur

Module de représentation

Le module existe en `pytorch`, il est idéal pour représenter les structure discrètes.

```
1       latent_size = 10
2       nb_users = 100
3       users = torch.nn.Embedding(nb_users, latent_size) # random init
4
5       # get representation of user 5:
6       print("User 5:", users(torch.tensor(5)))
7       # WARNING: call for a tensor (not an int)
```

Triplet loss / Constrastive Learning

- Rapprocher ce qui se ressemble... (+ Eloigner autre chose)

A l'ancienne: Siamese network

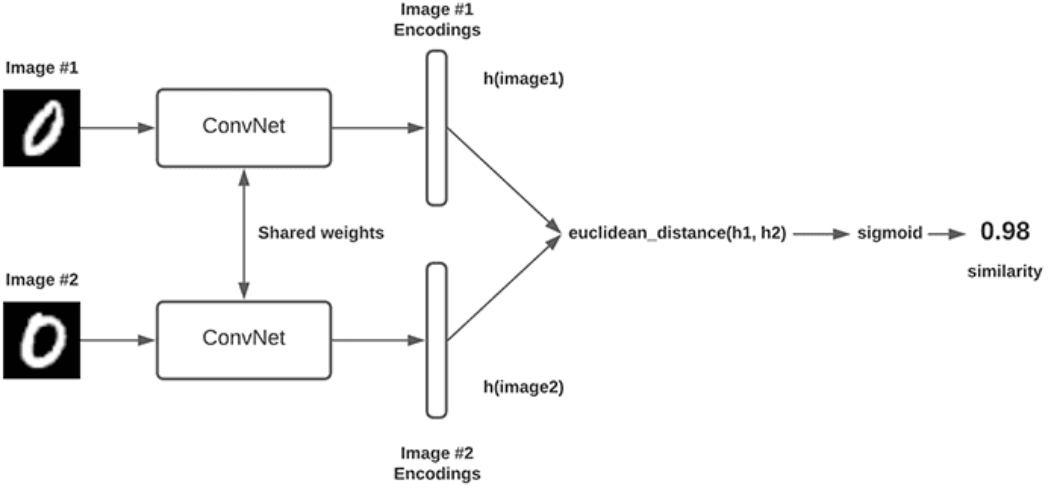

Triplet loss / Constrastive Learning

- Rapprocher ce qui se ressemble... (+ Eloigner autre chose)

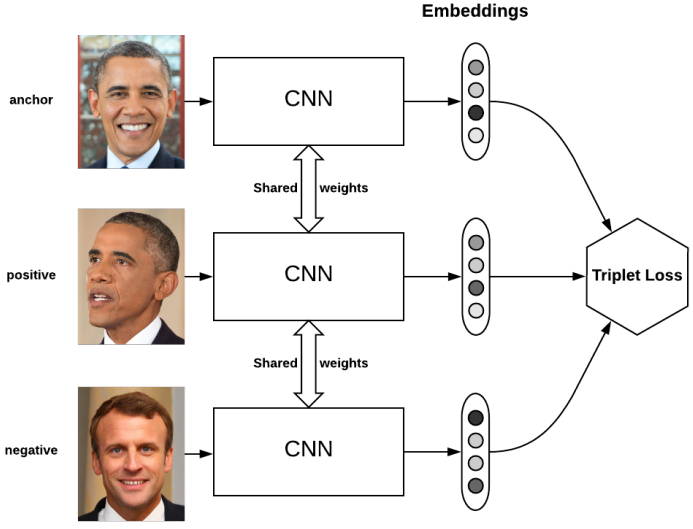

Conclusion

Evolution scientifique & pratique

80-90' Partage d'algorithmes et de données

2000' Partage d'implémentation de classifieur (SVM light, liblinear)

2010' Données massives + Plateforme de ML
& partage de modèle appris (Torch, W2V, ...)

2020' Généralisation de github, tensorflow, pytorch
+ interfaces d'accès e.g. HuggingFace

- Le plus grand levier de performances sur les 10 dernières années
- Très efficace sur les données sémantiques disponibles massivement
- Des modèles + complexes ET + accessibles

En texte, en image... Mais pas encore sur la classification de signaux

Modèle pré-appris/ Multi-tâches / Tranfert / Fine-tuning

Que faire maintenant?

- Plus de données (GPT2, 3, etc...),
- Plus de modalité (Grounding, visual language model)
- Plus de transfert (nouvelles tâches)

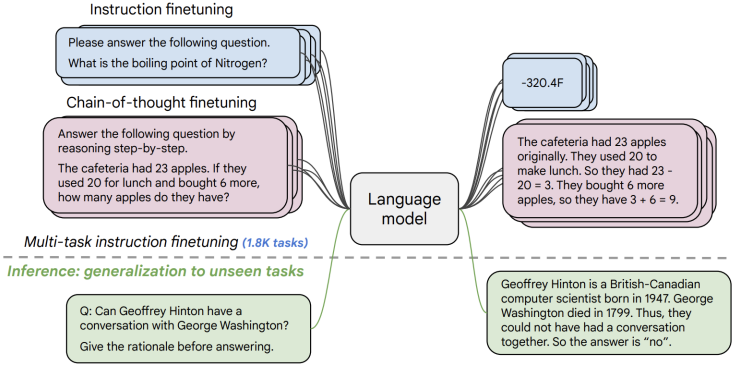

Modèle pré-appris/ Multi-tâches / Tranfert / Fine-tuning

Que faire maintenant?

- Plus de données (GPT2, 3, etc...),
- Plus de modalité (Grounding, visual language model)
- Plus de transfert (nouvelles tâches)

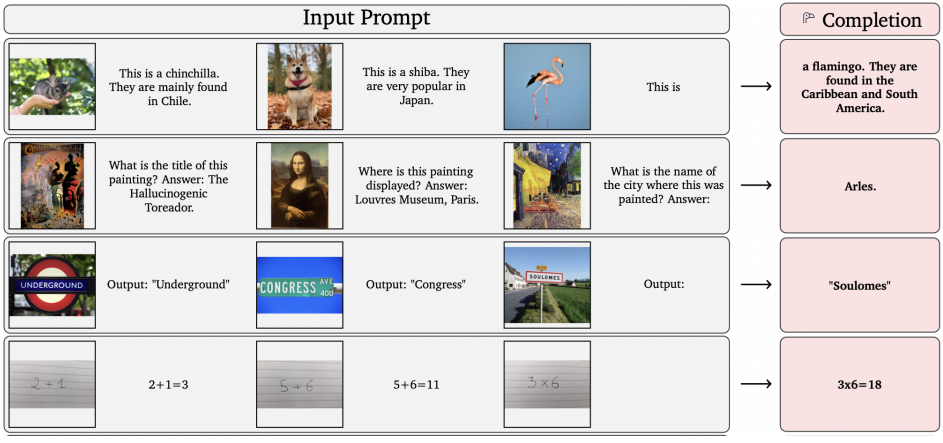

Quelle perspectives pour notre recherche

1. + de données, + de complexité
   - Difficile de jouer contre les GAFAM
2. Applications originales / implémentation de contraintes métiers développement de modèles
   - +/- de développement selon les cas d'usage
   - Jusqu'à des architectures nouvelles (CNN, LSTM, Transformer, RELU, ...)
3. Recherche de niches à fort potentiel
   - nouvelles problématiques: data-to-text, recommandation explicable
4. Recherche de propriétés théoriques
   - optimisation, prior sur l'espace latent (Nesterov, VAE, ...)
   - complémentarité intéressante mais complexe entre théorie et pratique

Niveaux d'usage des architectures deep:

- **Utilisateur** de modèles pré-entrainés
- **Affineur** sur de petit jeu de données, domaine applicatifs diverses
- **Entraineur** sur des données jouets (démonstration de concepts) / données massives
- **Développeur** pour jouer sur la plasticité